

แบบเสนอหัวข้อโครงการ รายวิชา 2301399 Project Proposal

ปีการศึกษา 2568

ชื่อโครงการ (ภาษาไทย)	การตรวจหาพลาสมิดบนสายลำดับพันธุกรรมด้วยระบบการเรียนรู้ของเครื่อง
ชื่อโครงการ (ภาษาอังกฤษ)	Plasmid Classification on DNA sequence with Machine Learning
อาจารย์ที่ปรึกษา	ผศ.ดร.นฤมล ประทานวนิช
ผู้ดำเนินการ	นายศิวัชร สายไพศรี เลขประจำตัวนิสิต 6634468023
	สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคณิตศาสตร์และวิทยาการคอมพิวเตอร์
	คณะวิทยาศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย

กลุ่มที่ 102

เอกสารนี้ได้รับการอนุมัติ

จากอาจารย์ที่ปรึกษาโครงการแล้ว

ลงชื่อ นางสาว ป.ส.

(วันที่ 3 พค 2569..)

หลังสอบเสร็จ

ให้ลบกล่องข้อความนี้

1. หลักการและเหตุผล

1.1. ความสำคัญของการจำแนกพลาสมิด

สารพันธุกรรมของแบคทีเรียโดยทั่วไปประกอบด้วยสองส่วนหลักคือ โครโมโซม (Chromosome) ซึ่งบรรจุยีนพื้นฐานที่จำเป็นต่อการดำรงชีวิต และ พลาสมิด (Plasmid) ซึ่งเป็นดีเอ็นเอนอกโครโมโซมที่มีลักษณะเป็นวงกลม พลาสมิดทำหน้าที่เป็นพาหะสำคัญในการส่งต่อชุดคำสั่งพิเศษระหว่างแบคทีเรียผ่านการถ่ายโอนยีนในแนวนอน (Horizontal Gene Transfer) โดยเฉพาะยีนดื้อยาต้านจุลชีพ (Antimicrobial Resistance: AMR) ซึ่งองค์การอนามัยโลก (WHO) ระบุว่าเป็นหนึ่งในภัยคุกคามทางสาธารณสุขที่ร้ายแรงที่สุดของโลก [1] การจำแนกความแตกต่างระหว่างลำดับพันธุกรรมของพลาสมิดและโครโมโซมจึงมีความสำคัญอย่างยิ่งในการระบุตำแหน่งของยีนดื้อยา และทำความเข้าใจกลไกการแพร่ระบาดของเชื้อในระดับจีโนม

1.2. ปัญหาในการจำแนกประเภทพลาสมิด

การแยกแยะว่าลำดับดีเอ็นเอที่ตรวจพบมาจากโครโมโซมหรือมาจากพลาสมิดเป็นขั้นตอนพื้นฐานที่มีความซับซ้อน เนื่องจากพลาสมิดและโครโมโซมมีการแลกเปลี่ยนชิ้นส่วนพันธุกรรมระหว่างกันอย่างรวดเร็ว ทำให้มีความหลากหลายเชิงโครงสร้างสูงและมีบางส่วนที่มีลำดับคล้ายคลึงกัน ข้อมูลจากฐานข้อมูล PLSDB แสดงให้เห็นถึงความแปรผันของขนาดและรูปแบบที่มีมหาศาล [3] ส่งผลให้วิธีการวิเคราะห์ทางสถิติดั้งเดิมยังคงประสบกับข้อจำกัดหลายประการเมื่อต้องรองรับปริมาณข้อมูลขนาดใหญ่ (Big Data) ในปัจจุบัน

1.3. ข้อจำกัดของงานวิจัยในอดีต

วิธีการคำนวณที่ใช้ในการจำแนกประเภทพลาสติกในปัจจุบันยังมีข้อจำกัดที่สำคัญ ดังนี้:

- 1.3.1. **วิธีการจัดเรียงลำดับ (Alignment-based methods เช่น BLAST):** แม้จะมีความแม่นยำสูงแต่ต้องอาศัยความคล้ายคลึงกับข้อมูลเดิมในฐานข้อมูลเป็นหลัก หากเผชิญกับพลาสติกสายพันธุ์ใหม่หรือพลาสติกที่มีอัตราการกลายพันธุ์สูง ประสิทธิภาพจะลดลงอย่างมาก [7]
- 1.3.2. **วิธีการนับความถี่ของ k-mer (Alignment-free methods):** เน้นความรวดเร็วในการประมวลผล แต่การวิเคราะห์เพียงความถี่ของชิ้นส่วนสั้นๆ ทำให้สูญเสีย "บริบท" หรือความสัมพันธ์เชิงโครงสร้างและลำดับของยีน
- 1.3.3. **การใช้ยีนเครื่องหมาย (Marker genes):** การตรวจหาลำดับเฉพาะ (Signature sequences) ซึ่งหากพลาสติกมีการกลายพันธุ์หรือขาดลำดับดังกล่าว จะทำให้การจำแนกประเภทล้มเหลว [2]

1.4. แนวทางที่นำเสนอ

โครงการนี้จึงเสนอการใช้ **สถาปัตยกรรม Transformer** ซึ่งเป็นเทคโนโลยีพื้นฐานของแบบจำลองภาษาขนาดใหญ่ (LLMs) มาประยุกต์ใช้ในการสร้างค่าตัวแทนเชิงบริบท (Contextual Embeddings) จากลำดับโปรตีน โดยอาศัยหลักการเดียวกับแบบจำลอง **ProtBERT** หรือ **ESM** ที่มองว่าลำดับกรดอะมิโนเปรียบเสมือนภาษาทางชีวภาพ [6] มีขั้นตอนหลักคือการถอดรหัสจากลำดับ DNA ไปสู่ลำดับโปรตีน (DNA-to-protein encoding) เพื่อสกัดคุณลักษณะเชิงหน้าที่ (Functional Features) ซึ่งจะช่วยให้แบบจำลองสามารถจับความสัมพันธ์เชิงโครงสร้างของพลาสติกได้ลึกซึ้งกว่าการวิเคราะห์ลำดับตัวอักษรเพียงอย่างเดียว

2. วัตถุประสงค์

เพื่อพัฒนาแบบจำลองการเรียนรู้เชิงลึก จำแนกประเภทลำดับดีเอ็นเอระหว่างพลาสติกและโครโมโซมในกลุ่มแบคทีเรีย โดยใช้การประมวลผลค่าตัวแทนเชิงบริบท (Embeddings) จากลำดับโปรตีนที่ถอดมาจากลำดับดีเอ็นเอ

3. ขอบเขตของโครงการงาน

- 3.1. ข้อมูลที่ใช้: ข้อมูลลำดับพันธุกรรมของพลาสมิดจากฐานข้อมูลมาตรฐาน ประกอบด้วย NCBI RefSeq หรือ PLSDB ซึ่งเป็นข้อมูลพันธุกรรมที่ได้รับการตรวจสอบความถูกต้องแล้วเท่านั้น
- 3.2. ประเภทของตัวอย่าง: มุ่งเน้นไปที่พลาสมิดในแบคทีเรีย

4. วิธีการดำเนินงาน

ในการดำเนินงานวิจัยนี้ผู้จัดทำได้ประยุกต์ใช้หลักการพัฒนาระบบตามวงจรการพัฒนาระบบ(System Development Life Cycle: SDLC) ร่วมกับระเบียบวิธีวิจัยทางวิทยาศาสตร์ข้อมูล (Data Science Methodology) โดยแบ่งขั้นตอนการดำเนินงานออกเป็น 5 ระยะ ดังนี้:

4.1. การศึกษาและวิเคราะห์ปัญหา (Requirement Analysis & Literature Review)

- 4.1.1. ศึกษาวรรณกรรมที่เกี่ยวข้องกับโครงสร้างทางพันธุกรรมของพลาสมิด และกลุ่มความไม่เข้ากัน (Incompatibility Groups)
- 4.1.2. ศึกษาทฤษฎีสถาปัตยกรรม Transformer และกลไก Self-Attention เพื่อนำมาประยุกต์ใช้กับลำดับทางชีวภาพ
- 4.1.3. วิเคราะห์ข้อจำกัดของเครื่องมือจำแนกประเภทพลาสมิดในปัจจุบัน (เช่น BLAST, PlasmidFinder)

4.2. การรวบรวมและจัดเตรียมข้อมูล (Data Collection & Preprocessing)

- 4.2.1. การรวบรวมข้อมูล: ดาวน์โหลดข้อมูลพลาสมิดจากฐานข้อมูล PLSDB และ NCBI RefSeq ในกลุ่มที่เป็น Complete Sequence โดยเป็นข้อมูลทางพันธุกรรมที่ถูกปรับปรุงไม่เกินเดือน สิงหาคม พ.ศ. 2569
- 4.2.2. การจัดเตรียมชุดข้อมูล:
- การทำสกัด Open Reading Frames (ORFs) เพื่อแปลงลำดับ DNA เป็นลำดับโปรตีน
 - การทำ Tokenization สำหรับลำดับกรดอะมิโนเพื่อให้โมเดลสามารถประมวลผลได้
 - การทำ Data Cleaning โดยกำจัดข้อมูลที่ซ้ำซ้อนหรือข้อมูลที่มีคุณภาพต่ำ

4.3. การออกแบบและพัฒนาแบบโมเดล (System Design & Implementation)

- 4.3.1. การออกแบบสถาปัตยกรรม: ออกแบบ Transformer Encoder ที่สามารถรับ Input เป็นลำดับโปรตีนและคืนค่าออกมาเป็น Contextual Embedding ประกอบกับส่วนของการทำ Classifier Model
- 4.3.2. การพัฒนาโมเดล: ใช้ภาษา Python ประกอบกับ Library ที่เกี่ยวข้อง สร้างโมเดลตั้งต้นตามการออกแบบสถาปัตยกรรม เรียนรู้กับชุดข้อมูล

4.3.3. การปรับแต่งโมเดล: ทดลองตั้งค่าการเรียนรู้ของโมเดลที่หลากหลายด้วยวิธี Fine Tune Hyperparameter และทดลองประกอบกับ Classifier Model ชนิดต่าง ๆ

4.4. การทดสอบและประเมินผล (Testing & Evaluation)

4.4.1. ทดสอบประสิทธิภาพของโมเดลด้วยชุดข้อมูลทดสอบ (Benchmark) กลางสำหรับเปรียบเทียบประสิทธิภาพของทุกโมเดลที่ทำการศึกษา

4.4.2. เปรียบเทียบผลลัพธ์กับวิธีการดั้งเดิม (Baseline) เช่น k-mer frequency ร่วมกับ Classifier Model

4.4.3. ประเมินผลด้วยตัวชี้วัดทางสถิติ ได้แก่ Accuracy, F1-Score และค่า Confusion Matrix

4.5. สรุปผลและจัดทำรายงาน (Documentation & Conclusion)

สรุปผลการดำเนินงานและจัดทำเอกสาร โดยสรุปผลการออกแบบและพัฒนาโมเดล อภิปรายข้อได้เปรียบและได้รับการพัฒนาจากการศึกษาครั้งก่อน พร้อมระบุข้อจำกัดและแนวทางการพัฒนาต่อยอดในอนาคต และจัดทำเอกสารสรุปโครงการฉบับสมบูรณ์

4.6. ระยะเวลาดำเนินการ (Operations Time Planning)

ขั้นตอนดำเนินการ	พ.ศ. 2569							พ.ศ. 2570			
	ม.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.	พ.ย.	ธ.ค.	ม.ค.	ก.พ.	มี.ค.	เม.ย.
การศึกษาและวิเคราะห์ปัญหา											
การรวบรวมและจัดเตรียมข้อมูล											
การออกแบบและพัฒนาโมเดล											
การทดสอบและประเมินผล											
สรุปผลและจัดทำรายงาน											

5. ประโยชน์ที่คาดว่าจะได้รับ

ประโยชน์ต่อตัวนิสิต: พัฒนาทักษะการใช้ Machine Learning ในงานด้าน Bioinformatics และการจัดการ Big Data ทางวิทยาศาสตร์

ประโยชน์ต่อด้านวิชาการ: ได้แนวทางใหม่ในการวิเคราะห์พลาสมิดที่ไม่ยึดติดกับการจัดเรียงลำดับ (Alignment-free) ซึ่งเป็นก้าวสำคัญในการศึกษาชีววิทยาสังเคราะห์

ประโยชน์ต่อสังคม: ช่วยเพิ่มประสิทธิภาพในการเฝ้าระวังเชื้อดื้อยา (AMR Surveillance) ซึ่งเป็นประโยชน์ต่อระบบสาธารณสุขในการวางแผนรับมือโรคติดเชื้อ

6. อุปกรณ์และเครื่องมือที่ใช้

- 6.1. เครื่องคอมพิวเตอร์พกพา จำนวน 2 เครื่อง
- 6.2. เครื่องคอมพิวเตอร์แม่ข่าย สำหรับงานวิจัย

7. งบประมาณ

- 7.1. ค่าบริการเครื่องมือปัญญาประดิษฐ์แบบมีค่าใช้จ่าย เช่น Google AI, ChatGPT, Claude
- 7.2. ค่าบริการการใช้ทรัพยากรบนระบบคลาวด์ เช่น Google Cloud, Google Colab

8. เอกสารอ้างอิง

[1] World Health Organization. Antimicrobial Resistance Fact Sheet. 2023. แหล่งที่มา: <https://www.who.int/news-room/fact-sheets/detail/antimicrobial-resistance>

[2] Carattoli A, Zankari E, García-Fernández A, Voldby Larsen M, Lund O, Villa L, et al. In Silico Detection and Typing of Plasmids using PlasmidFinder and Real-time Antigen Typing for Salmonella. Antimicrobial Agents and Chemotherapy. 2014. แหล่งที่มา: <https://aac.asm.org/content/58/7/3895>

[3] Galata V, Fehlmann T, Backes C, Keller A. PLSDb: A Comprehensive Database of Bacterial Plasmids. Nucleic Acids Research. 2019. แหล่งที่มา: <https://academic.oup.com/nar/article/47/D1/D1145/5127092>

[4] National Center for Biotechnology Information. BLAST® (Basic Local Alignment Search Tool). 2024. แหล่งที่มา: <https://blast.ncbi.nlm.nih.gov/Blast.cgi>

[5] Ji Y, Zhou Z, Liu H, Davuluri RV. DNABERT: Pre-trained Bidirectional Encoder Representations from Transformers for DNA-sequence Analysis. Bioinformatics. 2021. แหล่งที่มา: <https://academic.oup.com/bioinformatics/article/37/15/2112/6128376>

[6] Hugging Face. Deep Learning for Biology: Protein Language Models. 2024. แหล่งที่มา:
<https://huggingface.co/blog/deep-learning-biology>

[7] NCBI. RefSeq: NCBI Reference Sequence Database. 2024. แหล่งที่มา:
<https://www.ncbi.nlm.nih.gov/refseq/>

[8] UniProt. UniProt: The Universal Protein Resource. 2024. แหล่งที่มา:
<https://www.uniprot.org/>